

Laporan Tugas Akhir
Klasifikasi Sentimen Ulasan Pengguna terhadap
Layanan E-Wallet DANA di Google Play Store



Disusun oleh:

Ulfia Nurmalizha Ramadhani	(24031554064)
Aulia Aziza	(24031554102)
Fauziah Roikhana Wardah	(24031554162)

Dosen Pengampu:

Ulfa Siti Nuraini, S.Stat., M.Stat.
Nurul Laili, S.Pd., M.Sc.

PROGRAM STUDI S1 SAINS DATA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS NEGERI SURABAYA
TAHUN AJARAN 2025/2026

DAFTAR ISI

BAB I

PENDAHULUAN.....	2
A. Latar Belakang.....	2
B. Tujuan.....	2
C. Manfaat.....	3
D. Data Yang Digunakan.....	3

BAB II

METODE DAN ALUR KERJA.....	4
A. Pre-Processing.....	4
B. Feature Engineering.....	9
C. Metode.....	12
D. Analisis Kesesuaian Metode terhadap Tujuan Project.....	15
E. Metrik Evaluasi.....	15
F. Alur Kerja.....	17

BAB III

HASIL DAN ANALISIS.....	18
A. Hasil Pemodelan.....	18
B. Penentuan Metode Terbaik.....	27
C. Analisis Hasil Eksperimen.....	28

BAB IV

KESIMPULAN DAN SARAN.....	31
A. Kesimpulan.....	31
B. Kendala.....	31
C. Rencana Lanjutan.....	32
DAFTAR PUSTAKA.....	34
LAMPIRAN.....	36
A. Kontribusi Anggota.....	36
B. Link Data.....	37
C. Link Youtube.....	37
D. Link Google Colab.....	37

BAB I

PENDAHULUAN

A. Latar Belakang

Di era digital saat ini, penggunaan layanan dompet digital sudah semakin meluas di Indonesia sebagai alternatif pembayaran *non-tunai*. Aplikasi dompet digital seperti DANA telah menjadi salah satu pelaku utama dalam ekosistem keuangan digital. Melalui fitur-fitur seperti pembayaran tagihan, transfer saldo, pembayaran melalui QRIS, dan pembelian online, DANA mempermudah transaksi tanpa uang fisik yang sejalan dengan peningkatan adopsi uang elektronik di Indonesia ^[2]. Seiring meningkatnya jumlah pengguna, platform distribusi aplikasi seperti Google Play Store menjadi ruang bagi pengguna untuk memberikan penilaian serta ulasan yang menjelaskan pengalaman mereka dalam menggunakan layanan tersebut.

Meningkatnya popularitas DANA juga diiringi dengan timbulnya berbagai keluhan pengguna yang tercatat di dalam komentar Google Play Store, seperti kesulitan login, transaksi gagal, dan isu pengisian saldo, merupakan bagian yang perlu diperhatikan oleh pengembang aplikasi ^[3]. Kondisi ini menandakan bahwa meskipun aplikasi DANA telah banyak digunakan, masih terdapat persoalan dalam aspek keandalan sistem dan kepuasan pengguna ^[5]. Penelitian terdahulu oleh Sriani et al. (2024) juga menemukan adanya ulasan negatif yang cukup besar terkait performa dan kecepatan layanan ^[1].

Selain masalah teknis, isu keamanan transaksi digital juga menjadi perhatian utama pengguna dompet digital di Indonesia. Adanya berbagai kasus kejahatan siber, seperti *phising* yang bertujuan mencuri kode OTP dan *hacking* yang berujung pada penyalahgunaan data pribadi dan berkurangnya saldo pengguna, telah menimbulkan kekhawatiran serius terhadap jaminan akuntabilitas hukum dan keamanan finansial pada layanan dompet digital ^[4]. Di sisi lain, persaingan antara penyedia dompet digital seperti Go Pay, OVO, dan *ShopeePay* semakin ketat, sehingga DANA perlu mempertahankan citra dan kepercayaan pengguna dengan meningkatkan kualitas layanan dan stabilitas sistem ^[6].

Oleh karena itu, penting dilakukan analisis dan klasifikasi sentimen terhadap ulasan aplikasi DANA di Google Play Store untuk memahami persepsi pengguna secara lebih objektif. Melalui pendekatan *Natural Language Processing* (NLP), diharapkan mampu mengidentifikasi kecenderungan opini positif, negatif, atau netral terhadap berbagai aspek layanan aplikasi DANA. Hasil dari klasifikasi ini akan menjadi dasar bagi pengembangan dalam memperbaiki fitur, meningkatkan pengalaman pengguna, serta memperkuat kepercayaan publik terhadap layanan keuangan digital di Indonesia.

B. Tujuan

1. Menganalisis sentimen ulasan pengguna aplikasi DANA di Google Play Store.
2. Mengklasifikasikan ulasan pengguna aplikasi DANA di Google PlayStore menjadi sentimen positif, negatif, dan netral menggunakan metode TF-IDF,

Naive Bayes dan *Support Vector Machine* (SVM).

3. Mengidentifikasi aspek layanan yang sering mendapat tanggapan positif maupun negatif.
4. Mengevaluasi performa metode terbaik dengan metrik akurasi, presisi, dan *recall*.

C. Manfaat

1. Memberikan pengalaman praktis dalam penerapan teknik *pre-processing* dan *feature engineering*.
2. Menyediakan data terstruktur untuk prioritas perbaikan fitur, meningkatkan keandalan sistem, dan menjaga kepercayaan pengguna.
3. Menjadi dasar pembelajaran dalam menggunakan metode TF-IDF, *Naive Bayes* dan *Support Vector Machine* (SVM) pada Pemrosesan Teks.
4. Mengetahui hasil akurasi yang lebih baik dari metode yang digunakan.

D. Data Yang Digunakan

Pada Project ini data berupa ulasan pengguna aplikasi DANA yang diambil dari Google Play Store. Pengambilan data dilakukan melalui web scraping untuk mendapatkan 1000 baris data yang memuat informasi nama pengguna, rating, dan ulasan. Kemudian data yang sudah dikumpulkan tersebut disimpan dalam bentuk .xlsx agar bisa dipakai tahap selanjutnya yaitu pre-processing text, transformasi dengan metode TF-IDF (*Term Frequency-Inverse Document Frequency*), dan klasifikasi menggunakan algoritma *Naive Bayes*, juga *Support Vector Machine* (SVM) dalam mengelompokkan sentimen positif, negatif atau netral. Data diambil dari platform resmi Google Play Store agar informasi yang didapatkan akurat dan bisa dinilai kecenderungan sentimen pengguna terhadap aplikasi DANA.

BAB II

METODE DAN ALUR KERJA

A. Pre-Processing

1. Teknik Pre-Processing

Setelah mengumpulkan data dari hasil *scraping*, maka kami melakukan tahap *pre-processing* yaitu menghapus *stopword*, melakukan normalisasi (mengubah kata slang ke baku), dan menghapus emoji dengan bantuan *library* python *sastrawi*, *re*, dan *string*. *Pre-processing* membantu membuat teks/kalimat lebih terstruktur ^[8], agar data dapat digunakan ke tahapan selanjutnya. Berikut merupakan langka-langkah yang kami lakukan dalam *pre-processing* model ini:

a. Menyiapkan *Stopword*

Stopword adalah kumpulan kata yang akan dihapus dan tidak mempunyai arti yang bermakna, contohnya seperti kata *hubung* ^[8]. Dalam tahapan ini kami mengambil default *stopword* list dari *library* *sastrawi* dan menambahkan *custom stopwords* list dari dokumen yang telah kami punya. Namun kami mengecualikan kata “tidak”, “belum”, dan “banget” agar mempermudah proses *labeling* nantinya.

b. *Stemming*

Stemming adalah tahapan dimana kata imbuhan diubah menjadi kata dasar dengan pustaka python yang kami gunakan. Tahap ini mempengaruhi akurasi analisis sentimen ^[7]. Hal pertama yang kami lakukan adalah menginisialisasi *stemmer*.

c. Menghapus Emoji

Pada tahapan ini, menghapus seluruh emoji dan simbol-simbol dari teks.

d. *Case Folding*

Di dalam tahapan ini, semua huruf dalam teks akan diubah menjadi huruf kecil dengan menggunakan code yang kami masukkan ke dalam fungsi `clean_message`.

e. Menghapus Spasi Berlebih

Membersihkan spasi, tab, dan new line yang menumpuk.

f. Menghapus Angka

g. Menghapus URL

h. Menghapus hashtag

i. Menghapus karakter non-ASCII

j. Menghapus tanda baca

k. Normalisasi slang

Dalam tahapan normalisasi, dokumen yang memuat kata-kata tidak baku/slang akan diubah kedalam kata baku. Sebelumnya kami membuat dictionary yang berisi list kata dan kata bakunya.

```

normalisasi = {
    "bgt": "banget", "bg": "bang", "yg": "yang", "gk": "gak", "ga": "gak", "g": "gak",
    "ngga": "gak", "aja": "saja", "km": "kamu", "aku": "saya", "gw": "saya",
    "dr": "dari", "udh": "sudah", "tp": "tapi", "pls": "tolong", "wkwk": "haha",
    "hehe": "haha", "mba": "mbak", "cndu": "candu", "bngt": "banget", "gue": "saya",
    "gua": "saya", "aq": "saya", "apk": "aplikasi", "ttp": "tetap", "tpi": "tetapi",
    "tp": "tetapi", "appk": "aplikasi",
}

```

Lalu mengganti kata tidak baku tersebut berdasarkan kamus ini.

1. *Tokenizing*

Tokenizing adalah proses memecah kalimat menjadi kata-kata (token). Dalam project ini kami melakukannya secara manual menggunakan metode split (), sehingga kalimat/teks terbagi berdasarkan spasi, kemudian hasil pemisahan ini akan digunakan untuk normalisasi, stemming, dan penghapusan *stopword*.^[7]

m. *Stopword removal*

Setelah menyiapkan list *stopword* melalui pustaka sastrawi dan *custom stopwords*, kemudian kami akan menghapus *stopword* dengan code dibawah ini.

n. Mengurangi karakter berulang

Fungsi ini digunakan untuk mengurangi karakter yang berulang-ulang menjadi satu saja agar tidak mengganggu proses TF-IDF.

o. *Replace* dua puluh kata paling jarang muncul

Mengambil kata-kata yang paling jarang muncul karena biasanya itu adalah typo. Lalu membuat *dictionary* perbaikan untuk mengganti typo tersebut. Fungsi *apply_fix* kemudian digunakan untuk mengganti setiap kata sesuai kamus, dan hasilnya diterapkan ke kolom *full_text_clean* agar teks lebih rapi dan konsisten.

p. *Output* teks bersih untuk analisis selanjutnya

Setelah tahapan *pre-pocessing* selesai, maka selanjutnya akan dilakukan proses labeling.

Berikut merupakan 5 data pertama dari hasil *pre-processing* diatas.

Index	Messages	Full_text_clean	Score
0	sudah bagus sebenarnya, tapi dana cicil sering off/"sedang tidak tersedia" padahal limit saldo juga masih ada, aplikasi udah paling update,dan juga sinyal bagus. kenapa dah	bagus dana cicil off tidak sedia limit saldo aplikasi update sinyal bagus dah	3
1	Aplikasinya makin lama making problems, server error ketika mau Buat laporan ke Diana jadi tidak terkirim lampiranya, force close tiba2, seakan kena hack, Pengembalian Dana tidak Bisa karena server error. Sudah download ulang 1jt kali tetap tidak Bisa login kembali ke menu sebelumnya untuk	aplikasi making problems server error lapor ana tidak kirim lampiranya force close kena hack dana tidak server error download ulang jt kali tidak login	3

	log in,. A+ semakin tidak menarik, semakin lama apk ini semacam scam yg menipu, ketika mau dpt rewards pasti Gangguan sampe lewat tanggal untuk rewardsnya, belum lagi rewardsnya berubah yang Seharusnya 5k jd 50	menu belum log in a tidak tarik aplikasi scam tipu dpt rewards ganggu sampe tanggal rewardsnya belum rewardsnya ubah k jd	
2	dulu hilang uang dari dana suruh bikin laporan ke kepoliaian. sekarang pembayaran qris gak masuk masuk tapi saldo terpotong. dan kata nya gak bisa di kembalikan lagi.	hilang uang dana suruh bikin lapor kepoliaian bayar qris masuk masuk saldo potong	1
3	kami sangat kecewa karena proses ganti nomer hp yang hilang dipersulit. sudah jelas saya yang punya email dan sudah saya kirim persyaratan yang anda minta mengapa masih ragu dengan anda alasan meminta laporan ke kepolisian. sudah jelas saya yang meminta merubah nomer HP karena nomer lama saya hilang. kenapa tidak ada buat 3 pertanyaan keamanan dari buat daftar baru, biar akses pindah nomer hp ga di persulit.	kecewa proses ganti nomer hp hilang sulit email kirim syarat ragu alas lapor polisi rubah nomer hp nomer hilang tidak aman daftar biar akses pindah nomer hp sulit	5
4	tolong perbaiki di pembayaran QR nya masa mau beli Kouta lewat qris malah ga bisa ada gangguan lah katanya padahal sinyal baik ² aja	bayar qr beli kouta qris ganggu sinyal	1

2. Exploratory Data Analysis Tahap Pre-Processing

Setelah tahapan *pre-processing* selesai, selanjutnya dilakukan *Exploratory Data Analysis (EDA)* untuk menganalisis karakteristik ulasan. Berdasarkan pemeriksaan awal, yaitu pengecekan distribusi fitur *score* (rating aplikasi yang diberikan pengguna) melalui `df.score.value_counts()`, ditunjukkan bahwa sebagian besar ulasan memberikan rating rendah (1 bintang). Lalu dianalisis, apakah pengguna cenderung menulis ulasan panjang atau singkat dengan menghitung jumlah kata pada satu teks.


Hasilnya didapatkan bahwa kebanyakan pengguna menuliskan ulasan secara detail berdasarkan pengalaman mereka. Selanjutnya kami menghitung frekuensi kata yang paling sering dalam ulasan pengguna aplikasi DANA, dimana kata yang paling besar menandakan paling sering muncul. Dari gambar dibawah, kata “dana”, “tidak”, “aplikasi”, “transaksi”, “masuk”, “saldo”, dan

“uang” mendominasi, yang berarti pengguna sering menyebutkan nama aplikasi dan membicarakan masalah login serta transaksi.



Gambar 1. kata yang sering muncul


Grafik histogram dibawah (gambar 2), menunjukkan jumlah kata per ulasan, ditemukan bahwa mayoritas ulasan memiliki panjang kalimat sekitar 20-35 kata, dimana seperti yang dikatakan sebelumnya pengguna menuliskan ulasan dengan detail bukan hanya satu-dua kata.



Gambar 2. distribusi panjang ulasan


Untuk mendapatkan pemahaman tentang topik utama yang dibahas pengguna, kami menghitung frekuensi kata yang paling sering muncul dalam ulasan. *Word Cloud* dan 10 Kata Teratas: Visualisasi *Word Cloud* dan Grafik Batang 10 Kata Paling Sering Muncul memperkuat hasil secara kuantitatif. Pada (Gambar 3) terdapat 10 kata yang sering muncul yang mendominasi ulasan. Kata yang paling sering muncul adalah “dana”, diikuti oleh “tidak”, “aplikasi”, “akun”, “saldo”, “premium”, “masuk”, “uang”, “transaksi”, dan

“nomor” berarti pengguna sering menyebutkan nama aplikasi dan membicarakan masalah login, transaksi, dan saldo. Kata “tidak” sering muncul sekitar 800 kali, yang merupakan indikasi kuat bahwa sentimen negatif cukup dominan dalam keseluruhan ulasan.



Gambar 3. 10 kata paling sering muncul

Pada grafik (Gambar 4) dibawah, rating yang ditunjukkan didominasi oleh bintang 1 dengan frekuensi tertinggi yaitu 552 ulasan. Hal ini menunjukkan tingkat kepuasan pengguna yang sangat rendah. Data statistik lebih lanjut menunjukkan rata-rata rating sebesar 2.25 dan median rating sebesar 1.0, mengidentifikasi bahwa distribusi yang sangat condong ke rating terendah.



Gambar 4. distribusi rating aplikasi

Berdasarkan hasil EDA, dataset yang terdiri dari 1000 ulasan pengguna aplikasi DANA dengan distribusi rating didominasi oleh bintang 1. Visualisasi wordcloud menunjukkan bahwa kata yang paling sering muncul adalah “dana”, “tidak”, “aplikasi”, “masuk”, “nomor”, “akun”, “transaksi”, “hilang”, “kode”, “saldo”, menandakan mayoritas ulasan bersifat negatif. Secara keseluruhan, data telah bersih dan siap digunakan untuk tahap feature engineering.

B. Feature Engineering

1. Metode Feature Engineering

Sebelum melakukan *feature engineering* kami terlebih dahulu memberikan label pada data. Pelabelan ini berguna sebagai pemberi label klasifikasi sentimen pada teks yang sudah melalui tahapan *pre-processing* [8]. Tahap pelabelan dilakukan menggunakan pendekatan lexicon-based dengan kamus sentimen InSet (*Indonesian Sentiment Lexicon*). Kami mengunduh dua berkas lexicon berisi daftar kata positif dan negatif, lengkap dengan bobot sentimennya. Setiap kata pada kedua daftar tersebut kemudian kami ubah menjadi dictionary Python, yaitu `positive_lex` dan `negative_lex`, lalu kami gabungkan menjadi satu kamus besar bernama `inset_lex`.

Proses pelabelan dilakukan secara semi-otomatis melalui fungsi `auto_label_inset()`. Fungsi ini membaca setiap kata dalam teks yang telah melalui proses *pre-processing*, lalu menjumlahkan skor sentimen berdasarkan bobot kata dari InSet. Jika total skor lebih besar dari 0 maka teks diberi label positif, jika kurang dari 0 diberi label negatif, dan jika total nilai sama dengan 0 maka diberi label netral. Setelah diberikan label maka kita bisa melakukan *feature engineering* dengan menggunakan TF-IDF, yaitu tahapan yang berfungsi memberikan nilai bobot pada teks. tujuannya agar algoritma *Naive Bayes* dan SVM nantinya dapat memahami teks [8]. Menurut Hanani (2023) konsep dasar TF mengukur seberapa sering suatu kata muncul dalam teks, lalu IDF akan menilai seberapa unik kata tersebut. Gabungan TF-IDF inilah yang nantinya menciptakan bobot untuk setiap kata [9]. Pada project ini, implementasi dilakukan menggunakan *library scikit-learn* (modul *sklearn*) dengan parameter `max_features = 5000`, yang membatasi jumlah fitur pada 5000 kata terpenting, serta `ngram_range = (1,2)` yang mempertimbangkan kombinasi kata tunggal (*unigram*) dan pasangan kata (*bigram*).

a. Vectorization

Mengubah teks menjadi angka agar dapat diproses oleh model machine learning.

b. Inisialisasi dan Konfigurasi TfidfVectorizer

Mengatur pola untuk mencocokkan kata, memastikan hanya kata-kata yang terdiri dari minimal 2 huruf yang akan dipertimbangkan, sehingga mengabaikan karakter atau kata yang sangat pendek.


c. Menghitung jumlah fitur

d. Memastikan tidak ada baris kosong

- e. Menampilkan kata kunci paling dominan


2. Exploratory Data Analysis Tahap Feature Engineering

Untuk memahami hasil transformasi TF-IDF serta distribusi label sentimen, kami melakukan beberapa tahapan analisis. Grafik dibawah ini (gambar 5) disusun berdasarkan distribusi rata-rata nilai TF-IDF per fitur, ditunjukkan bahwa sebagian besar kata memiliki nilai TF-IDF mendekati nol, yang menunjukkan bahwa mayoritas kata dalam korpus muncul secara umum di banyak teks, sehingga teks dinilai kurang informatif.



Gambar 5. distribusi rata-rata nilai TF-IDF per fitur


Selanjutnya, kita bisa melihat (gambar 6) 20 kata paling informatif berdasarkan TF-IDF, yang memperlihatkan bahwa kata “tidak”, “dana”, “aplikasi”, “nomor”, “masuk”, “akun”, “hilang” menempati posisi teratas, yang menunjukkan bahwa topik pembahasan berkaitan erat dengan permasalahan teknis dan transaksi pada akun.



Gambar 6. 20 kata paling informatif


Dari label sentimen, kita bisa memvisualisasikan distribusinya seperti grafik dibawah ini (gambar 7). Tertera bahwa sekitar 800 ulasan menunjukkan

sentimen negatif terhadap aplikasi tersebut. Artinya, sebagian besar ulasan dari pengguna berisi kekecewaan, marah, dan tidak puas terhadap layanan aplikasi yang digunakan.



Gambar 7. distribusi label sentiment

Terakhir, hasil heatmap korelasi (gambar 8) antara fitur TF-IDF menunjukkan korelasi yang cukup rendah diantara sebagian besar kata. Warna biru yang dominan pada heatmap mengindikasikan bahwa antar fitur (kata) memiliki hubungan yang lemah, atau dengan kata lain, masing-masing kata muncul secara independen dalam konteksnya masing-masing. Meski demikian, terdapat beberapa pasangan kata yang memiliki korelasi cukup tinggi, misalnya “*abisa*” dan “*abis uang*”, yang kemungkinan sering muncul bersamaan dalam konteks pembahasan tentang keadilan proses transaksi di dalam aplikasi.



Gambar 8. heatmap korelasi antar fitur

Secara keseluruhan, kami dapat menyimpulkan bahwa mayoritas kata bersifat general, dan dominasi sentimen negatif menunjukkan adanya kecenderungan ketidakpuasan pengguna terhadap aplikasi e-wallet DANA ini. Sedangkan korelasi antar fitur yang rendah menegaskan efektivitas TF-IDF dalam menghasilkan fitur yang independen.

C. Metode

Metode yang digunakan dalam project ini adalah kombinasi dari algoritma *Naive Bayes Multinomial* dan *Support Vector Machine (SVM)* untuk klasifikasi sentimen, serta k-means clustering untuk analisis mendalam pada sentimen. Kedua algoritma tersebut dipilih karena memiliki tingkat akurasi tinggi dalam klasifikasi sentimen. klasifikasi dilakukan terhadap data yang telah dilakukan *pre-processing* dan *feature engineering* dengan TF-IDF untuk mengubah teks ulasan menjadi representasi numerik.

Pada tahapan klasifikasi, algoritma *Naive Bayes Multinomial* digunakan karena memperhitungkan frekuensi kemunculan kata dalam dokumen ^[1]. Sedangkan SVM digunakan untuk mencari *hyperplane* terbaik yang memisahkan data antar kelas dengan margin maksimum dan analisis perbandingan antara *Naive Bayes Multinomial* dan SVM manakah yang memiliki tingkat akurasi yang tinggi ^[10]. Untuk penerapan algoritma *Naive Bayes Multinomial* dan *SVM* menggunakan *library python scikit-learn (sklearn)*.

1. *Naive Bayes Multinomial*

Naive Bayes merupakan salah satu algoritma *machine learning* yang diawasi berlabel (*supervised learning*) yang digunakan untuk menangani masalah klasifikasi berdasarkan pada probabilitas atau kemungkinan sesuai dengan Teorema Bayes. Kata *Naive* dalam metode ini dilandaskan pada asumsinya

terhadap sebuah kata dalam teks yang dianggap independen satu sama lain. Meskipun pada kenyataannya asumsi ini sering tidak tepat, tetapi bisa membuat perhitungan menjadi lebih efisien dan efektif.

Dalam project ini *Naive Bayes Multinomial* cocok digunakan karena memperhitungkan frekuensi kata dan bisa menganalisis sentimen pada ulasan pengguna aplikasi DANA. Prinsip kerjanya menghitung probabilitas sebuah teks masuk ke kelas “positif” atau “negatif” dengan mengalikan probabilitas awal kelas dengan probabilitas setiap kata dalam teks yang muncul di kelas itu^[11].

Proses *training model* berawal dari mengestimasi dua parameter *train data*. Pertama, model akan menghitung *prior probability* dari kedua kelas, yaitu seberapa banyak kemunculan kelas “positif” atau “negatif”. Kedua, model akan menghitung *conditional probability* dari seberapa sering suatu kata muncul di dalam teks berlabel “positif” atau “tidak negatif”^[11].

$$P(c|d) \propto P(c) \prod_{1 \leq k \leq n_d} P(t_k|c)$$

Keterangan:

$P(c|d)$ = Probabilitas dokumen d termasuk kelas c

$P(c)$ = Prior (probabilitas kelas c)

t_k = Term ke- k dalam dokumen

n_d = Jumlah term dalam dokumen

$P(t_k|c)$ = probabilitas term t_k muncul di kelas c

$\langle t_1, t_2, \dots, t_{n_d} \rangle$ = Urutan token dalam dokumen d yang digunakan dalam proses klasifikasi

$\prod_{1 \leq k \leq n_d}$ = Perkalian probabilitas seluruh token t_k dari token pertama hingga

token ke- n_d dengan asumsi independensi bersyarat (*naive assumption*)

$\propto$ = $P(c|d)$ sebanding dengan hasil di ruas kanan, sehingga klasifikasi dilakukan dengan membandingkan nilai antar kelas tanpa normalisasi

2. *Support Vector Machine (SVM)*

SVM merupakan salah satu metode dalam *supervised learning* yang biasanya digunakan untuk klasifikasi (seperti *Support Vector Classification*) dan regresi (*Support Vector Regression*). SVM digunakan dalam project ini sebagai pembanding untuk mengevaluasi metode *Naive Bayes*, dengan tujuan mengetahui sentimen ulasan pengguna aplikasi DANA. Algoritma ini juga menghasilkan *hyperplane* terbaik yang memisahkan data antar kelas dengan margin maksimum.

Pada permasalahan klasifikasi teks, data umumnya memiliki jumlah fitur yang sangat besar dan bersifat *high-dimensional*. Joachims (1998) menyatakan bahwa permasalahan klasifikasi teks biasanya melibatkan ruang fitur berdimensi tinggi. Karakteristik ini membuat SVM sangat sesuai digunakan pada representasi teks seperti *bag of words* maupun TF-IDF yang bersifat *sparse* dan berdimensi tinggi^[12].

Prinsip optimasi pada SVM dirancang untuk menyeimbangkan antara margin maksimum dan kesalahan klasifikasi, yang berdampak pada kemampuan generalisasi model^[13]. Secara matematis, fungsi keputusan SVM dirumuskan sebagai masalah optimasi soft margin yang bertujuan meminimalkan norma bobot serta kesalahan klasifikasi, sebagaimana ditunjukkan pada persamaan berikut.

$$\min_{w,b,\xi} \frac{1}{2} w^T w + C \sum_{i=1}^l \xi_i$$

dengan kendala:

$$y_i(w^T \phi(x_i) + b) \geq 1 - \xi_i,$$

$$\xi_i \geq 0, i = 1, \dots, l,$$

Fungsi keputusan SVM untuk proses klasifikasi dinyatakan dalam bentuk tanda dari kombinasi kernel dan support vectors.

$$\text{sgn } w^T \phi(x) + b = \text{sgn} \left(\sum_{i=1}^l y_i \alpha_i K(x_i, x) + b \right)$$

Untuk data yang tidak dapat dipisahkan secara linear, SVM menggunakan pendekatan soft margin dengan parameter regularisasi C yang mengatur trade-off antara margin dan kesalahan klasifikasi^[13]. Dalam project ini, SVM digunakan sebagai metode pembandingan terhadap Naive Bayes untuk klasifikasi sentimen ulasan pengguna aplikasi DANA, karena SVM mampu menangani fitur TF-IDF yang bersifat *sparse* dan berdimensi tinggi.

3. K-Means Clustering

K-Means merupakan algoritma unsupervised learning yang digunakan untuk melakukan *clustering* atau pengelompokan data. Tujuan K-Means adalah membagi kumpulan data menjadi K kelompok berbeda dengan meminimalkan variansi antar data dalam cluster dan memaksimalkan variansi antar kelompok^[14].

$$d(x, y) = \sqrt{(\sum_{i=1}^n (x_i - y_i)^2)}$$

Keterangan:

d = Selisih jarak data point x dan y

x = Nilai data ke-i

y = Nilai centroid data ke-i

n = Jumlah atribut data

Dalam project ini, K-Means digunakan untuk menganalisis ulasan pengguna

yang telah diklasifikasikan masing-masing sentimennya yaitu positif dan negatif secara terpisah untuk menemukan topik yang lebih spesifik. Penentuan jumlah *cluster* menggunakan *Shillouette score* dan memilih nilai yang menghasilkan *score* rata-rata tertinggi, sehingga cluster yang dihasilkan adalah jumlah *cluster* yang baik. Selanjutnya hasil clustering akan dianalisis pada masing-masing sentimen. Sentimen positif menunjukkan aspek-aspek yang dinilai baik oleh pengguna dan sentimen negatif juga menunjukkan berbagai permasalahan yang dialami pengguna, mulai dari gangguan akses akun, hambatan pada proses *top-up* dan transfer, keterlambatan penanganan keluhan oleh *customer service*, hingga kesalahan tampilan aplikasi. Melalui pendekatan tersebut, K-Means berperan sebagai metode analitis yang mampu mengonversi ulasan pengguna yang masih bersifat mentah dan tidak terstruktur menjadi insight yang jelas dan terorganisasi, sehingga hasilnya dapat dijadikan acuan dalam penentuan strategi pengembangan serta peningkatan mutu produk dan layanan secara berkelanjutan.

D. Analisis Kesesuaian Metode terhadap Tujuan Project

Kombinasi TF-IDF, *Naive bayes*, dan *SVM* terhadap project ini sesuai dengan tujuannya yaitu klasifikasi sentimen ulasan pengguna aplikasi DANA. TF IDF berfungsi sebagai penyeimbang bobot kata umum, sedangkan *Naive Bayes Multinomial* dan *SVM* dapat memberikan hasil klasifikasi yang efisien pada data teks yang berukuran kecil hingga besar. Keduanya dapat menghasilkan sentimen yang dikategorikan (positif, negatif, atau netral) sehingga di akhir nanti dapat diambil kesimpulan kecenderungan pengguna aplikasi DANA. Perbandingan akurasi antara kedua algoritma ini akan menghasilkan kesimpulan yang kuat dan tepat untuk digunakan dalam klasifikasi sentimen ulasan.

K-Means melengkapi analisis ini dengan memberikan perspektif unsupervised yang efektif untuk mengelompokkan ulasan berdasarkan topik keluhannya ^[14]. Hasil klasterisasi ini dapat dimanfaatkan untuk menganalisis masalah dengan lebih cepat dan efisien, serta memberikan kesimpulan yang lebih mendalam mengenai kecenderungan pengguna di luar label sentiment ^[14].

E. Metrik Evaluasi

Dalam memilih model klasifikasi sentimen *Naive bayes* atau *SVM* yang memiliki performa terbaik perlu menggunakan beberapa metrik dari *sklearn.metrics*, yaitu *accuracy*, *precision*, *recall*, *f1-score*, *macro average*, *weighted average*, serta *confusion matrix* ^[10]. Percobaan dalam *Confusion matrix* dihitung menggunakan matrik berikut:

1. *Confusion matrix* digunakan untuk melihat detail prediksi benar dan salah pada masing-masing kelas. Matriks ini membantu mengidentifikasi kesalahan model, seperti kecenderungan memprediksi suatu kelas secara berlebihan atau kekurangan. Pada klasifikasi multi kelas dengan tiga kelas, yaitu 1 (positif), 0 (negatif), dan 2 (netral), *confusion matrix* berbentuk matriks 3×3 yang memetakan jumlah prediksi benar dan salah antar kelas.

Secara umum, *True Positive* (TP) adalah jumlah data dari suatu kelas yang diprediksi dengan benar, *False Positive*(FP) adalah jumlah data dari kelas lain yang salah diprediksi sebagai kelas tersebut, *False Negative*(FN) adalah jumlah data dari kelas tersebut yang salah diprediksi sebagai kelas lain, dan *True Negative*(TN) adalah jumlah data dari kelas lain yang diprediksi dengan benar bukan sebagai kelas tersebut.

2. *Accuracy* digunakan untuk mengukur persentase prediksi dengan benar berdasarkan data. Namun jika hanya memakai accuracy masih belum cukup, sehingga pada evaluasi ditambahkan penggunaan metrik seperti *precision*, *recall*, dan *f1-score*.

$$Accuracy = \frac{TP+TN}{TP+FP+FN+TN}$$

3. *Precision* menunjukkan tingkat ketepatan model dalam memprediksi suatu kelas, yaitu seberapa banyak prediksi benar dibanding total prediksi pada kelas tersebut.

$$Precision = \frac{TP}{TP+FP}$$

4. *Recall* menunjukkan seberapa baik model berhasil menemukan seluruh data dalam suatu kelas.


$$Recall = \frac{TP}{TP+FN}$$

5. *F1 score* untuk menunjukkan rata-rata dari precision dan recall sehingga memberikan penilaian yang lebih seimbang, terutama pada kondisi data dengan distribusi kelas yang tidak merata.

$$F1 - Score = 2 \frac{Precision \times Recall}{Precision + Recall}$$

6. *Macro average* untuk menghitung rata-rata metrik pada setiap kelas tanpa mempertimbangkan jumlah data, sehingga menunjukkan keseimbangan prediksi antar kelas.
7. *Weighted average* digunakan untuk mempertimbangkan banyaknya data pada masing-masing kelas, sehingga memberikan gambaran yang lebih sesuai secara keseluruhan terutama ketika jumlah data tiap kelas tidak sama.

F. Alur Kerja



Gambar 9. Alur Kerja

Project analisis sentimen ulasan pengguna aplikasi *e-wallet* DANA ini direncanakan melalui beberapa tahapan, agar analisis akurat dalam merepresentasikan opini pengguna. Pertama, mengumpulkan data ulasan pengguna aplikasi dana yang bersumber dari *google play store* dengan melakukan *scraping*, lalu data yang didapatkan akan disimpan dalam file excel. Data ini akan disiapkan agar siap dianalisis dengan melalui tahapan *pre-processing*, yaitu menghapus duplikasi spasi, tanda baca, angka, karakter non alfabet, *case folding* atau mengubah semua huruf menjadi huruf kecil, melakukan *stemming*, dan menghapus *stopwords*.

Setelah data dipastikan bersih, selanjutnya data akan diberi label menggunakan *Lexicon based* dan merubah teks menjadi numerik dengan menggunakan metode TF-IDF pada proses *feature engineering*. Output dari proses ini adalah matriks dan kolom label sentimen yang digunakan dalam pemodelan. Selanjutnya, tahap pemodelan dilakukan dengan menerapkan dua algoritma klasifikasi, yaitu *Naive Bayes* dan *Support Vector Machine* (SVM). Kedua model dipilih karena setelah menilik dari penelitian terdahulu, keduanya memiliki performa yang baik dalam klasifikasi.

Model dilatih dengan data hasil *feature engineering*, lalu dievaluasi menggunakan matrix *accuracy*, *precision*, *recall*, *f1-score*, *macro average*, dan *weighted average* untuk mendapatkan nilai keakuratan masing-masing algoritma pemodelan, serta untuk menentukan model terbaik. Setelah semuanya selesai, tahap

selanjutnya adalah visualisasi dan analisis hasil pemodelan, dimana hasil prediksi sentimen akan divisualisasikan dalam bentuk grafik dan *wordcloud* untuk memudahkan melihat gambaran persebaran sentimen pengguna terhadap aplikasi DANA. Lalu dilakukan proses *clustering* dengan menggunakan algoritma *K-Means* untuk mendapatkan inti pembahasan dari kedua kelas yang ada. Dan terakhir, analisis keseluruhan hasil yang telah didapatkan sehingga bisa melakukan inferensi tentang bagaimana sentimen pengguna terhadap aplikasi DANA ditilik dari data yang telah didapatkan.

BAB III HASIL DAN ANALISIS

A. Hasil Pemodelan

Pada tahap ini dilakukan proses pemodelan menggunakan dua algoritma klasifikasi, yaitu *Multinomial Naive Bayes* dan *Support Vector Machine* (SVM). Dimana, sebelum pemodelan, dataset dibagi menjadi 80% data latih dan 20% data uji menggunakan fungsi `train_test_split()` dari *library scikit learn*.

```
from sklearn.model_selection import train_test_split

X = X_tfidf

y = df['label_inset']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)

print("Data training:", X_train.shape)
print("Data testing:", X_test.shape)
```

1. Hasil Pemodelan Menggunakan Multinomial Naive Bayes

Model pertama dibangun dengan algoritma Naive Bayes. Algoritma ini dipilih karena mampu memproses data berupa frekuensi kata seperti TF-IDF. Model ini dilatih menggunakan data training, dan kemudian dilakukan prediksi dengan data uji. Implementasi model dilakukan menggunakan modul Multinomial NB pada library *scikit_learn*.

```
from sklearn.naive_bayes import MultinomialNB

nb_model = MultinomialNB()

nb_model.fit(X_train, y_train) #latih menggunakan data training

y_pred_nb = nb_model.predict(X_test)

print("Prediksi Sentimen Naive Bayes:")
print(y_pred_nb[:20])
```

Model ini kemudian menghasilkan prediksi seperti berikut

```
Prediksi Sentimen Naive Bayes:
['negatif' 'negatif' 'negatif' 'negatif' 'negatif' 'negatif' 'negatif'
 'negatif' 'negatif' 'negatif' 'negatif' 'negatif' 'negatif' 'negatif'
 'negatif' 'negatif' 'negatif' 'negatif' 'negatif' 'negatif']
```

Gambar 10. output Multinomial Naive Bayes

Evaluasi model dilakukan dengan beberapa metrik, yaitu *akurasi*, *precision*, *recall*, *f1-score*, dan *confusion matrix* dengan menggunakan library *sklearn.metrics*.

```
print("Evaluasi Naive Bayes:")
print("Accuracy:", accuracy_score(y_test, y_pred_nb))
print(classification_report(y_test, y_pred_nb))
print(confusion_matrix(y_test, y_pred_nb))
```

Evaluasi Naive Bayes:

Accuracy: 0.835

	precision	recall	f1-score	support
negatif	0.83	1.00	0.91	167
netral	0.00	0.00	0.00	3
positif	0.00	0.00	0.00	30
accuracy			0.83	200
macro avg	0.28	0.33	0.30	200
weighted avg	0.70	0.83	0.76	200

[[167	0	0]
[3	0	0]
[30	0	0]]

Gambar 11. Output Evaluasi Naive Bayes

Hasil evaluasi kemudian menunjukkan tingkat akurasi model adalah 83,5%. Model ini memiliki *recall* yang sangat tinggi, yaitu 1.00 pada kategori sentimen negatif. *Recall* kelas negatif yang sangat tinggi bukan berarti model bekerja dengan sangat baik. Hal ini terjadi karena data sangat tidak seimbang, sehingga model hanya belajar pola dari kelas negatif yang jumlahnya dominan. Akibatnya, kelas netral dan positif tidak terprediksi dengan baik, membuat model menjadi bias dan kurang mampu membedakan variasi sentiment lain.

Dominasi jumlah data negatif dengan 167 sampel, Naive Bayes terdorong mempelajari pola kata negatif secara berlebihan. Sifat Naive Bayes yang mengandalkan probabilitas kata jika sebuah teks mengandung satu kata negatif, model langsung memberikan probabilitas tinggi sebagai negatif. Model sangat bias ke kelas negatif, sehingga meskipun akurasinya tinggi, kemampuan membedakan sentimen lain sangat buruk (macro avg, f1 = 0.30). *Naive Bayes* tidak mampu menangani imbalance dan variasi kata pada kelas positif atau netral.

2. Hasil Pemodelan Menggunakan Support vector Machine (SVM)

```
from sklearn.svm import SVC
```

```
svm_model = SVC(kernel='linear', C=1)
```

Mengimpor model SVM untuk klasifikasi, menggunakan SVC (*Support Vector Classifier*) dari library scikit-learn. Membuat model SVM dengan parameter kernel='linear' SVM akan mencari garis pemisah *linear* antar kelas (positif, netral, negatif), C=1 (nilai standar) Parameter yang mengatur kompromi antara margin yang lebar dan kesalahan klasifikasi. Jika nilai C semakin kecil, margin lebih lebar, toleransi error lebih besar.

```
svm_model.fit(X_train, y_train)
```

Menginisialisasi model SVM menggunakan `X_train = fitur hasil TF-IDF`, `y_train = label sentimen (positif, netral, negatif)`, SVM akan mencari batas pemisah terbaik antara sentimen-sentimen tersebut.

```
y_pred_svm = svm_model.predict(X_test)

print("Prediksi SVM (20 contoh):")
print(y_pred_svm[:20])
```

Model akan melakukan prediksi terhadap data dengan mengambil 20 elemen indeks 0 sampai 19 kemudian menghasilkan sebuah array berisi label sentimen yang diprediksi oleh SVM.

```
Prediksi SVM (20 contoh):
['negatif' 'negatif' 'negatif' 'negatif' 'negatif' 'negatif' 'negatif'
 'negatif' 'negatif' 'negatif' 'negatif' 'negatif' 'negatif' 'negatif'
 'negatif' 'negatif' 'negatif' 'negatif' 'negatif' 'negatif']
```

Gambar 12. Output SVM

Dari output diatas menunjukkan bahwa model SVM dapat menangkap perbedaan pola kata dan konteks dalam ulasan pengguna, sehingga tidak dominan ke satu sentimen tertentu saja. Oleh karena itu, model tidak hanya mengenali ulasan positif atau negatif, tetapi juga mampu mengidentifikasi ulasan yang bersifat ambigu atau tidak menunjukkan emosi yang kuat sebagai sentimen netral. Keluaran ini mengindikasikan bahwa SVM dapat bekerja secara efektif dalam mengklasifikasikan ulasan pengguna terhadap aplikasi DANA, karena mampu memberikan prediksi yang beragam sesuai isi teks. Keberhasilan model dalam memunculkan ketiga label secara proporsional dan memperlihatkan bahwa proses preprocessing, dan TF-IDF vectorization berjalan dengan benar.

```
print("Evaluasi SVM")
print("Accuracy:", accuracy_score(y_test, y_pred_svm))
print(classification_report(y_test, y_pred_svm))
print(confusion_matrix(y_test, y_pred_svm))
```

Evaluasi SVM

Accuracy: 0.87


	precision	recall	f1-score	support
negatif	0.87	0.99	0.93	167
netral	0.00	0.00	0.00	3
positif	0.89	0.27	0.41	30
accuracy			0.87	200
macro avg	0.59	0.42	0.45	200
weighted avg	0.86	0.87	0.84	200

[[166	0	1]
[3	0	0]
[22	0	8]]

Gambar 13. Output Evaluasi SVM

Hasil evaluasi menunjukkan bahwa model SVM mencapai akurasi sebesar **87%**, yang berarti mayoritas prediksi sentimen sesuai dengan data sebenarnya. Secara keseluruhan SVM memberikan hasil lebih stabil dibandingkan Naive Bayes. Recall negatif 0.99 menunjukkan hampir semua data negatif terdeteksi. Recall positif masih rendah yaitu 0.27, tetapi jauh lebih baik daripada Naive Bayes. Dan recall netral sama seperti Naive Bayes, kelas netral yang jumlahnya sangat sedikit tidak dapat dipelajari model.

3. Clustering Menggunakan K-Means




Gambar 14. Silhouette Score Sentimen Positif

Proses clustering juga dilakukan secara terpisah untuk ulasan dengan sentimen positif dan negatif menggunakan pendekatan yang sama, yaitu K-Means pada representasi TF-IDF. Untuk menentukan jumlah kluster terbaik pada sentimen positif, perhitungan Silhouette Score dilakukan pada rentang

K=2 hingga K=10. Nilai tertinggi terdapat pada K=7, sehingga model K-Means dioptimalkan menggunakan tujuh kluster untuk memetakan pola utama pada ulasan positif. Setelah proses pelatihan selesai, setiap ulasan positif memperoleh label kluster 0 sampai 6 yang menggambarkan kemiripan kata antar-ulasan.


Cluster	Kata
0	'dana', 'akun', 'akun dana', 'lapor', 'min', 'saldo', 'hilang', 'tidak', 'terima', 'kecewa', 'kirim', 'chat', 'cs', 'masuk', 'transaksi', 'pakai', 'kak', 'bukti', 'kalo', 'hilang saldo'
1	'bisnis', 'dana', 'dana bisnis', 'proses', 'transaksi', 'tarik', 'jual', 'coba', 'saldo', 'uang', 'bayar', 'tidak', 'aplikasi', 'qr', 'cair', 'stabil', 'tari', 'reksa', 'reksa dana', 'jam'
2	'cicil', 'dana cicil', 'dana', 'fitur', 'fitur dana', 'muncul', 'transaksi', 'aplikasi', 'juta', 'tidak', 'kasih', 'belum', 'instan', 'dana instan', 'bintang', 'limit', 'aplikasi dana', 'akun', 'kecewa', 'kasih bintang'
3	'premium', 'dana', 'dana premium', 'update', 'aplikasi dana', 'aplikasi', 'tarik', 'diupgrade', 'ngk', 'jdi', 'premium update', 'belum', 'tunggu', 'akun', 'kasih', 'transaksi', 'kasih bintang', 'pas', 'verifikasi', 'bintang'
4	'upgrade', 'premium', 'kirim', 'uang', 'upgrade premium', 'kirim uang', 'suruh', 'dana', 'suruh upgrade', 'kali', 'dana premium', 'upgrade dana', 'akun', 'pas', 'muncul', 'transfer', 'gabisa', 'transaksi', 'tarik tunai', 'uang suruh'
5	'wajah', 'jaring', 'verifikasi wajah', 'jaring bagus', 'verifikasi', 'login', 'bagus', 'dana', 'otp', 'saldo', 'pake', 'akun', 'loading jaring', 'loading', 'tele', 'relog', 'kali', 'paket', 'layar', 'ny'
6	'up', 'top', 'top up', 'saldo', 'dana', 'game', 'aplikasi', 'saldo dana', 'cepat', 'masuk', 'kecewa', 'ku', 'bayar', 'belum', 'up game', 'up saldo', 'akses', 'pake', 'email', 'transaksi'



Gambar 15. Scatter Plot Sentimen Positif

Sumbu PC1 (Principal Component 1) dan PC2 (Principal Component 2) merupakan hasil reduksi dimensi menggunakan Principal Component Analysis (PCA), di mana PC1 menjelaskan variasi data terbesar, sedangkan PC2 menjelaskan variasi terbesar kedua yang tidak saling berkorelasi dengan PC1. Dengan demikian, posisi titik pada grafik menunjukkan kemiripan pola ulasan berdasarkan fitur teks yang telah diekstraksi.

Cluster 0 terkait akun dan saldo yang sempat bermasalah namun dapat ditangani dengan baik, Cluster 1 berfokus pada fitur keuangan yang lebih kompleks seperti Dana Bisnis dan Reksa Dana, dengan isu utama terkait proses tarik dan cair dana. Cluster 2 berisi ulasan mengenai kendala akses ke fitur pinjaman seperti Dana Cicil dan Dana Instan, di mana pengguna kecewa karena fitur tersebut tidak muncul di akun mereka. Cluster 3 dan Cluster 4 berkaitan erat dengan proses upgrade ke Dana Premium; Cluster 3 menyoroti penundaan verifikasi setelah update aplikasi, sementara Cluster 4 membahas pembatasan yang memaksa pengguna suruh upgrade agar dapat kirim uang atau tarik tunai. Cluster 5 mencerminkan masalah teknis pada login dan verifikasi wajah yang sensitif terhadap kondisi jaring (jaringan) dan loading. Terakhir, Cluster 6 fokus pada layanan Top Up saldo, terutama untuk game, dengan ulasan yang didominasi oleh kecepatan masuk namun ada pula keluhan kecewa terkait proses pembayaran. Secara keseluruhan, klaster-klaster ini menunjukkan perlunya perbaikan pada keamanan, aksesibilitas fitur premium/pinjaman, dan stabilitas teknis aplikasi.




Gambar 16. Silhouette Score Sentimen Negatif

Pada tahap clustering untuk sentimen negatif, proses unsupervised learning menggunakan algoritma K-Means dilakukan untuk mengelompokkan ulasan berdasarkan kemiripan kata pada representasi TF-IDF. Tidak ada label sentimen yang digunakan pada proses ini, model murni membentuk kelompok berdasarkan pola alami dalam data. Berdasarkan hasil perhitungan Silhouette Score, nilai tertinggi diperoleh pada K=6, sehingga jumlah klaster optimal untuk sentimen negatif ditetapkan menjadi enam kelompok. Setelah model K-Means dilatih menggunakan matriks TF-IDF, setiap ulasan mendapatkan label klaster mulai dari 0 hingga 5 yang menunjukkan kemiripan konten antar-ulasan dalam klaster tersebut.

Cluster	Kata
0	'cicil', 'dana cicil', 'dana', 'fitur', 'tidak', 'cicil tidak', 'fitur dana', 'limit', 'sedia', 'pakai', 'tidak sedia', 'bayar', 'muncul', 'transaksi', 'aplikasi', 'limit dana', 'mudah', 'aju dana', 'akun', 'kasih'
1	'upgrade', 'premium', 'upgrade premium', 'suruh upgrade', 'suruh', 'akun', ' kirim', 'uang', 'tidak', 'dana', 'aplikasi', 'muncul', ' kirim uang', 'dana premium', 'klik', 'transfer', 'upgrade dana', 'ktp', 'pakai', 'foto'
2	'masuk', 'aplikasi', 'dana', 'bagus', 'update', 'tidak', 'buka', 'jaring', 'saldo', 'uang', 'aplikasi dana', 'data', 'transaksi', 'coba', 'banget', 'error', 'kalo', 'tidak masuk', 'mohon', 'beli'
3	'dana', 'tidak', 'aplikasi', 'akun', 'transaksi', 'bantu', 'kecewa', 'premium', 'kali', 'nomer', 'hadiah', 'banget', 'daftar', 'uang', 'aplikasi dana', 'cs', 'dana tidak', 'ganti', 'nomor', 'saldo'

4	'bayar', 'saldo', 'aplikasi', 'tidak', 'uang', 'potong', 'dana', 'aman', 'transaksi', 'lengan', 'hilang', 'otomatis', 'saldo tidak', 'fitur', 'saldo potong', 'aplikasi dana', 'gogle', 'pakai', 'kecewa', 'pake'
5	'nomor', 'otp', 'kode', 'akun', 'kode otp', 'tidak', 'login', 'hilang', 'wajah', 'aktif', 'verifikasi', 'dana', 'verifikasi wajah', 'pin', 'tidak aktif', 'no', 'ganti', 'masuk', 'hp', 'pindah'



Gambar 17. Scatter Plot Sentimen Negatif

Berdasarkan hasil visualisasi PCA 2D pada data hasil clustering, setiap titik merepresentasikan ulasan pengguna yang telah direduksi dimensinya menggunakan Principal Component Analysis (PCA). PC1 (Principal Component 1) merupakan komponen utama yang menjelaskan variasi terbesar dalam data, sedangkan PC2 (Principal Component 2) menjelaskan variasi terbesar kedua yang tidak berkorelasi dengan PC1. Dengan demikian, jarak dan posisi titik pada grafik PC1–PC2 mencerminkan tingkat kemiripan pola keluhan pengguna berdasarkan fitur teks yang digunakan dalam proses clustering.

Dari hasil clustering menunjukkan bahwa Cluster 0 fokus pada ketidaktersediaan fitur Dana Cicil dan Limit, yang tidak sedia bagi pengguna. Cluster 1 menunjukkan frustrasi tinggi karena pengguna suruh upgrade premium dan menyerahkan ktp hanya untuk dapat melakukan transaksi dasar seperti kirim uang atau transfer. Isu teknis mendominasi Cluster 2, yang ditandai oleh aplikasi yang eror, tidak masuk, atau gagal buka setelah update. Cluster 3 menyoroti keluhan terkait akun yang bermasalah setelah ganti nomor atau pelayanan CS yang lambat dan membuat kecewa. Masalah finansial yang paling serius muncul di Cluster 4, di mana pengguna melaporkan saldo potong

secara otomatis atau hilang, menimbulkan kekhawatiran tentang keamanan dan apakah dana aman. Terakhir, Cluster 5 adalah kelompok keluhan terkait masalah aksesibilitas dan keamanan saat login, seperti kegagalan mendapatkan kode otp atau verifikasi wajah yang tidak aktif saat ganti perangkat.

B. Penentuan Metode Terbaik


Dari hasil evaluasi, terlihat bahwa kedua model memiliki performa yang berbeda. Algoritma *Multinomial Naive bayes* menunjukkan recall yang sangat tinggi pada kelas negatif (1.00), namun kurang optimal untuk memprediksi kelas netral dan positif karena adanya kemiripan pola kata yang dianggap masih termasuk kategori ketidakpuasan, dengan akurasi model mencapai 83,5%. Sedangkan algoritma *Support Vector Machine* (SVM) menghasilkan performa yang lebih stabil dalam memprediksi ketiga kategori sentimen tersebut, dengan akurasi model mencapai 87%.

Nilai *precision*, *recall*, dan *f-1 score* pada model SVM memperlihatkan distribusi yang lebih merata daripada *Naive Bayes*, karena cara kerja SVM yang mencari hyperplane optimal sebagai batas kelas. Hyperplane tersebut dipilih berdasarkan jarak terlebar antara titik data dari masing-masing kelas. Sehingga lebih unggul ketika menggunakan dataset bersifat *sparse* atau banyak nilai nol. Oleh karena itu, selain nilai akurasi yang lebih tinggi SVM lebih mampu membedakan ekspresi sentimen yang ambigu dan ulasan dengan kata-kata kompleks dibandingkan pemodelan dengan *Naive Bayes*.

Lalu, jika dilihat dari nilai *macro average*, model *Naive Bayes* menunjukkan performa yang kurang merata antar kelas, yang mengindikasikan adanya bias terhadap kelas negatif. Sementara itu, nilai *weighted average* pada model SVM lebih tinggi dan konsisten, menunjukkan bahwa model tersebut mampu mempertahankan kinerja yang baik meskipun distribusi data tidak seimbang. Dengan demikian, evaluasi melalui *macro* dan *weighted average* semakin menguatkan bahwa SVM memiliki performa yang lebih stabil dibandingkan *Naive Bayes*.

Hasil penelitian ini sejalan dengan penelitian sebelumnya yang membandingkan algoritma *Support Vector Machine* (SVM) dan *Naive Bayes* dalam klasifikasi sentimen teks. Penelitian pada *Jurnal Minfo Polgan* menunjukkan bahwa SVM menghasilkan nilai akurasi, *precision*, *recall*, dan *F1-score* yang lebih tinggi dibandingkan *Naive Bayes*, sehingga dinilai lebih stabil dalam memisahkan kelas sentimen^[15]. Hal ini disebabkan oleh kemampuan SVM dalam membentuk hyperplane keputusan dengan margin maksimum, sehingga lebih efektif dalam menangani data berdimensi tinggi. Hasil serupa juga ditunjukkan dalam penelitian pada *Jurnal Pendidikan dan Teknologi Indonesia (JPTI)*, yang menyatakan bahwa SVM memiliki performa yang lebih baik pada data teks dengan fitur *TF-IDF* yang bersifat *sparse*, sedangkan *Naive Bayes* bergantung pada asumsi independensi antar kata yang kurang optimal pada teks nyata^[16]. Oleh karena itu, temuan ini yang menunjukkan performa SVM lebih stabil dan merata dibandingkan *Naive Bayes* dalam klasifikasi sentimen ulasan pengguna aplikasi DANA didukung oleh penelitian-penelitian sebelumnya.

C. Analisis Hasil Eksperimen



Gambar 18. Diagram batang perbandingan Naive bayes dan SVM

Hasil eksperimen dalam penelitian ini mencakup pemodelan klasifikasi sentimen menggunakan dua algoritma, yaitu *Multinomial Naive Bayes* (MNB) dan *Support Vector Machine* (SVM), serta analisis kluster menggunakan metode K-Means. Kedua model klasifikasi dilatih pada dataset yang sama dengan proporsi 80% data latih dan 20% data uji, yang sebelumnya telah melalui proses *pre-processing* dan ekstraksi fitur menggunakan TF-IDF. Berdasarkan evaluasi performa, SVM menunjukkan hasil yang lebih unggul dibandingkan MNB pada hampir seluruh metrik. Pada metrik akurasi, MNB memperoleh nilai 83,5%, sedangkan SVM mencapai 87%, menunjukkan bahwa SVM mampu memberikan prediksi sentimen yang lebih sesuai dengan data sebenarnya. Pada metrik recall untuk kelas negatif, kedua model sama-sama menghasilkan nilai yang sangat tinggi (MNB = 1.00, SVM = 0.99), namun tingginya *recall* pada MNB terjadi karena model terlalu bias terhadap kelas dengan jumlah data terbesar sehingga gagal mengenali kelas lain secara efektif. Hal ini terlihat dari *recall* kelas positif pada MNB yang bernilai 0.00, sementara SVM mampu mencapai nilai 0.27, yang menunjukkan kemampuannya dalam mendeteksi kelas minoritas dengan lebih baik.

```

*** Evaluasi Naive Bayes:
Accuracy: 0.835
      precision    recall  f1-score   support

   negatif      0.83      1.00      0.91      167
    netral      0.00      0.00      0.00       3
   positif      0.00      0.00      0.00      30

   accuracy            0.83      200
  macro avg      0.28      0.33      0.30      200
 weighted avg      0.70      0.83      0.76      200

[[167  0  0]
 [  3  0  0]
 [ 30  0  0]]
Evaluasi SVM
Accuracy: 0.87
      precision    recall  f1-score   support

   negatif      0.87      0.99      0.93      167
    netral      0.00      0.00      0.00       3
   positif      0.89      0.27      0.41      30

   accuracy            0.87      200
  macro avg      0.59      0.42      0.45      200
 weighted avg      0.86      0.87      0.84      200

[[166  0  1]
 [  3  0  0]
 [ 22  0  8]]

```

Gambar 19. Evaluasi Naive Bayes

Perbedaan ini semakin terlihat pada nilai *macro average* F1-score, di mana MNB hanya mencapai 0.30, sedangkan SVM memperoleh 0.45. Nilai *macro average* menggambarkan keseimbangan performa antar kelas, sehingga skor yang lebih tinggi pada SVM menunjukkan bahwa model ini bekerja lebih stabil pada ketiga kelas sentimen. Nilai *weighted average F1-score* juga memperlihatkan keunggulan SVM dengan skor 0.84, sementara MNB berada pada 0.76. Hal ini menunjukkan bahwa SVM lebih konsisten dalam memprediksi data pada berbagai kelas meskipun *dataset* memiliki ketidakseimbangan distribusi yang cukup tinggi.

Secara keseluruhan, hasil evaluasi memperlihatkan bahwa SVM menjadi model yang lebih kompetitif dibandingkan *Multinomial Naive Bayes*. SVM tidak hanya memiliki akurasi yang lebih tinggi, tetapi juga memberikan prediksi yang lebih seimbang dan tidak terlalu bias terhadap kelas tertentu, sehingga lebih sesuai digunakan untuk tugas klasifikasi sentimen pada *dataset* ulasan pengguna aplikasi DANA.

Berdasarkan analisis K-Means pada data ulasan pengguna, dilakukan pengelompokan terhadap sentimen positif dan negatif untuk mengidentifikasi pola utama pengalaman pengguna terhadap aplikasi. Pada sentimen positif, terbentuk tujuh klaster yang menunjukkan bahwa meskipun ulasan secara umum positif, keluhan spesifik yang berulang masih ditemukan. Klaster-klaster tersebut terfokus pada isu akun dan saldo yang pada akhirnya terdapat di Cluster 0, kendala proses tarik dan pencairan dana pada fitur keuangan kompleks seperti Dana Bisnis dan Reksa Dana

Cluster 1, serta masalah aksesibilitas fitur pinjaman seperti Dana Cicil dan Dana Instan yang tidak tersedia pada akun pengguna Cluster 2. Selain itu, terdapat klaster yang berkaitan dengan penundaan verifikasi dan pembatasan fitur akibat proses upgrade ke Dana Premium Cluster 3 dan Cluster 4, permasalahan teknis pada proses login dan verifikasi wajah Cluster 5, serta keluhan pada layanan top up saldo dan pembayaran game meskipun kecepatan transaksi relatif baik Cluster 6. Secara keseluruhan, hasil ini menegaskan bahwa peningkatan kualitas layanan perlu difokuskan pada aspek keamanan, aksesibilitas fitur premium dan pinjaman, serta stabilitas teknis aplikasi.

Pada sentimen negatif, dengan jumlah klaster $K = 6$ yang ditetapkan sebagai nilai optimal berdasarkan evaluasi Silhouette Score. Hasil clustering menghasilkan enam klaster utama yang merepresentasikan fokus kekecewaan pengguna terhadap aplikasi. Cluster 0 mencerminkan keluhan terkait ketidaktersediaan fitur pinjaman dan limit, seperti Dana Cicil dan Limit, yang tidak muncul pada akun pengguna. Cluster 1 menunjukkan tingkat frustrasi yang tinggi akibat kebijakan paksaan upgrade ke akun premium, di mana pengguna diwajibkan melakukan verifikasi tambahan hanya untuk dapat menjalankan transaksi dasar seperti kirim uang atau transfer. Cluster 2 didominasi oleh isu teknis aplikasi, yang ditandai dengan error, kegagalan membuka aplikasi, atau gangguan sistem setelah pembaruan versi. Cluster 3 menyoroti permasalahan akun setelah pergantian nomor serta kualitas layanan customer service yang dinilai lambat dan tidak responsif. Cluster 4 merepresentasikan masalah finansial paling serius, yaitu laporan saldo terpotong secara otomatis atau hilang, sehingga menimbulkan kekhawatiran signifikan terkait keamanan dana pengguna. Terakhir, Cluster 5 berkaitan dengan kendala aksesibilitas dan keamanan saat proses login, seperti kegagalan menerima kode OTP dan verifikasi wajah yang tidak berfungsi, terutama saat pengguna mengganti perangkat. Secara keseluruhan, hasil klasterisasi pada sentimen negatif ini menunjukkan bahwa prioritas perbaikan perlu difokuskan pada peningkatan stabilitas teknis aplikasi, transparansi dan fleksibilitas kebijakan upgrade premium, serta keamanan dan keandalan pengelolaan dana pengguna.

BAB IV

KESIMPULAN DAN SARAN

A. Kesimpulan

Proyek analisis sentimen terhadap ulasan pengguna aplikasi DANA pada Google Play Store yang dilakukan dengan pendekatan Natural Language Processing (NLP) melalui pemanfaatan TF-IDF, Multinomial Naive Bayes, Support Vector Machine (SVM), serta K-Means Clustering menghasilkan beberapa kesimpulan berdasarkan pengolahan data, mayoritas ulasan yang dianalisis menunjukkan kecenderungan sentimen negatif. Dari total 1000 ulasan, sekitar 800 diantaranya berisi keluhan serta didominasi oleh rating bintang satu. Kondisi ini mengindikasikan adanya tingkat ketidakpuasan pengguna yang cukup tinggi terhadap kualitas layanan aplikasi DANA.

Pada tahap pemodelan klasifikasi sentimen, SVM sebagai algoritma dengan performa terbaik. Dengan akurasi sebesar 87%, model ini mampu memberikan hasil prediksi yang lebih stabil dan lebih efektif dalam membedakan ulasan positif, netral, dan negatif dibandingkan dengan Multinomial Naive Bayes yang memperoleh akurasi 83,5%. Meskipun kedua model mengalami ketidakseimbangan kelas dalam dataset, SVM tetap menunjukkan kemampuan yang lebih konsisten dalam menangkap pola bahasa dan variasi sentimen pengguna.

Analisis lebih lanjut menggunakan K-Means Clustering memberikan gambaran yang lebih mendalam mengenai jenis keluhan yang paling sering muncul. Dua kelompok utama berhasil diidentifikasi. Kelompok pertama berisi keluhan terkait kegagalan transaksi, gangguan fitur, dan permasalahan saldo. Sementara itu, kelompok kedua memuat masalah yang berkaitan dengan akses akun dan keamanan, seperti kesulitan login, verifikasi OTP, nomor telepon yang tidak aktif, hingga kekhawatiran terkait keamanan akun. Temuan ini dapat menjadi dasar bagi pihak pengembang untuk meninjau aspek-aspek layanan yang perlu mendapat prioritas perbaikan.

B. Kendala

Pada bagian ini memaparkan kendala dalam pengerjaan proyek ini, selama proses pengolahan data dan klasifikasi sentimen pada ulasan pengguna aplikasi DANA, serta solusi yang digunakan untuk menanganinya. Dataset awal hasil scraping memiliki 100 data hal tersebut kurang memadai untuk membangun model klasifikasi sentimen yang kuat dan mampu melakukan generalisasi dengan baik. Jumlah data yang sedikit berpotensi menghasilkan overfitting dan akurasi yang rendah. Kami melakukan proses scraping tambahan sehingga mencapai jumlah 1000 ulasan untuk memperbanyak dataset. Hal ini bertujuan untuk meningkatkan keragaman fitur linguistik dan menghasilkan model yang lebih akurat.

Data ulasan pengguna di Google Play Store mengandung banyak kesalahan pengetikan (typo), penggunaan huruf ganda secara berlebihan misalnya, "baangett",

dan simbol atau karakter yang tidak relevan. Kemudian kami melakukan teknik *pre-processing*, yaitu penghapusan spasi berlebih, penghapusan karakter non-ASCII, penanganan huruf ganda, dan Normalisasi Slang menggunakan kamus khusus. Dalam tahap pelabelan awal, kami menggunakan sistem semi-otomatis yang memanfaatkan analisis sederhana untuk mengklasifikasikan ulasan.

Sistem ini sering salah mengambil kesimpulan, di mana ulasan yang seharusnya bermuatan negatif diklasifikasikan sebagai positif atau netral, dan sebaliknya. Contohnya: "Tidak bisa login, kecewa banget." Sistem awal mungkin hanya fokus pada kata kecewa tanpa memahami konteks kata tidak. Kami melakukan koreksi terhadap dataset yang telah dilabeli secara semi-otomatis dan menambahkan beberapa kata lagi kedalam list kata-kata positif dan negatif agar sistem memiliki data latih yang lebih banyak. Setiap ulasan diperiksa dan dikoreksi sentimennya (Positif/Negatif/Netral) berdasarkan konteks keseluruhan teks. Tahap ini memastikan kebenaran data untuk pelatihan model.

Setelah menjalankan proses TF-IDF, terdapat keraguan mengenai keakuratan hasil karena matriks fitur yang dihasilkan didominasi oleh nilai nol. Jadi, kami menambahkan langkah verifikasi dengan memeriksa secara manual skor TF-IDF untuk kata-kata kunci tertentu. Selain itu, kami memeriksa ulang tokenizing dan stopword removal untuk memastikan tidak ada dokumen yang menjadi kosong setelah *pre-processing*, sehingga TF-IDF dapat menghitung skor dengan benar.

Sebelumnya, kami terkendala untuk membersihkan karakter berulang pada ulasan yang dapat mengganggu proses TF-IDF nantinya (contoh: "aduhhhhh"). Setelah mengikuti saran untuk mereplace 20 kata yang paling sedikit muncul ternyata juga tidak bisa mengatasi masalah tersebut. Akhirnya kami mendapatkan jalan keluar dengan membuat fungsi baru untuk dengan regex yang dapat mengurangi karakter berulang. Mengganti proses labelling yang awalnya menggunakan keyword based ke lexicon based membuat distribusi label bersifat imbalanced yang lebih ekstrim dari penggunaan metode sebelumnya. Ketidakseimbangan data latih ini membuat semua proses klasifikasi dan clustering menjadi berat ke kelas negatif dan menghasilkan precision atau recall 0 di class minoritas.

C. Rencana Lanjutan

Berdasarkan hasil analisis sentimen dan klasterisasi yang telah dilakukan, terdapat beberapa saran yang dapat diberikan baik kepada pihak pengembang aplikasi DANA maupun untuk penelitian selanjutnya. Bagi pengembang aplikasi DANA, hasil klasterisasi menunjukkan adanya dua kelompok keluhan utama yang perlu menjadi prioritas perbaikan. Masalah yang berkaitan dengan transaksi, stabilitas fitur, dan gangguan sistem yang teridentifikasi pada Cluster 0 sebaiknya menjadi fokus utama pengembangan, mengingat aspek tersebut paling sering dikeluhkan oleh pengguna. Selain itu, isu mengenai akses akun serta keamanan yang muncul pada Cluster 1 juga perlu mendapatkan perhatian serius. Prosedur terkait pergantian nomor telepon, verifikasi OTP, dan pemulihan akun perlu disederhanakan agar lebih mudah dipahami

pengguna, sekaligus disertai peningkatan sistem keamanan untuk meminimalkan risiko penyalahgunaan akun seperti phishing atau hacking.

Untuk penelitian selanjutnya, perlu diperhatikan bahwa ketidakseimbangan data merupakan salah satu tantangan utama dalam proses klasifikasi sentimen. Dominasi ulasan negatif pada dataset membuat model kurang optimal dalam mengenali kelas positif dan netral. Oleh karena itu, penelitian di masa mendatang dapat berfokus pada upaya memperbaiki distribusi data agar performa klasifikasi terhadap seluruh kelas menjadi lebih seimbang. Selain itu, penelitian lanjutan juga dapat mengeksplorasi pendekatan-pendekatan pemodelan yang mampu memahami konteks bahasa secara lebih mendalam sehingga hasil prediksi menjadi lebih akurat dan konsisten. Pengembangan analisis yang membandingkan berbagai pendekatan atau strategi juga dapat memberikan wawasan baru mengenai efektivitas teknik analisis sentimen pada dataset ulasan pengguna yang memiliki karakteristik serupa.

DAFTAR PUSTAKA

- [1] M. Audina Rambe, I. Komputer, S. dan Teknologi, and U. Islam Negeri Sumatera Utara, “Analisis Sentimen Pengguna Aplikasi Dana Menggunakan Metode Naïve Bayes,” 2024. Accessed: Nov. 07, 2025. Available: https://www.researchgate.net/publication/385869493_Analisis_Sentimen_Pengguna_Aplikasi_Dana_Menggunakan_Metode_Naive_Bayes/fulltext/6738492368de5e5a307824ac/Analisis-Sentimen-Pengguna-Aplikasi-Dana-Menggunakan-Metode-Naive-Bayes.pdf?origin=publication_detail&_tp=eyJjb250ZXh0Ijp7ImZpcnN0UGFnZSI6InB1YmxpY2F0aW9uIiwicGFnZSI6InB1YmxpY2F0aW9uRG93bmxxvYWQjLCJwcmV2aW91c1BhZ2UiOiJwdWJsaWNhdGlvbiJ9fQ
- [2] Bank Indonesia, “Monetary Policy Review December 2024,” Jakarta, Dec. 2024. Accessed: Nov. 08, 2025. [Online]. Available: Monetary Policy Review December 2024
- [3] G. Riansyah Ramadhan and C. Agus Sugianto, “ANALISIS SENTIMEN ULASAN APLIKASI DANA DI GOOGLE PLAY STORE MENGGUNAKAN ALGORITMA NAÏVE BAYES,” 2024.
- [4] G. Septia, R. Afria Ningsih, S. Dia Nurrul faadhilah, and D. Anugrah, “LETTERLIJK: JURNAL HUKUM PERDATA PERLINDUNGAN HUKUM TERHADAP PENGGUNA APLIKASI E-WALLET DANA ATAS KEJAHATAN LINK PHISING DAN HACKING PADA LAYANAN DIGITAL,” *LETTERLIJK*, 2024, doi: 10.25134/jise.v1i2.xx.
- [5] I. N. Dewi, R. Nurcahyo, and Farizal, “Assessment of mobile payment service based on user review in Indonesia,” *Communications in Humanities and Social Sciences*, vol. 4, no. 2, pp. 59–65, Dec. 2024, doi: 10.21924/chss.4.2.2024.81.
- [6] S. A. Ghaffar, “Comparative Sentiment Analysis of Digital Wallet Applications in Indonesia Using Naïve Bayes,” *IJIIS: International Journal of Informatics and Information Systems*, vol. 8, no. 2, pp. 55–66, Mar. 2025, doi: 10.47738/ijiis.v8i2.251.
- [7] N. Umar and M. A. Nur, “Application of Naïve Bayes Algorithm Variations On Indonesian General Analysis Dataset for Sentiment Analysis,” *Jurnal RESTI*, vol. 6, no. 4, pp. 585–590, 2022, doi: 10.29207/resti.v6i4.4179.
- [8] M. L. F. Martanto and W. Istiono, “Sentiment Analysis of M-Paspor App Reviews Using Multinomial Naive Bayes,” *Journal of Logistics, Informatics and Service Science*, vol. 11, no. 10, pp. 311–326, 2024, doi: 10.33168/JLISS.2024.1017.
- [9] A. Hanani, “ALGORITMA TERM FREQUENCY-INVERSE DOCUMENT FREQUENCY (TF-IDF),” 2023. [Online]. Available: <https://www.researchgate.net/publication/376720501>
- [10] A. Febriani, K. Umam, and I. Mustofa, “Implementation of Support Vector Machine for Classifying User Reviews on the Sentuh Tanahku Application,” 2025. [Online]. Available: <http://jurnal.polibatam.ac.id/index.php/JAIC>
- [11] C. D. Manning, P. Raghavan, and H. Schütze, *Introduction to Information Retrieval*. Cambridge, UK: Cambridge University Press, 2008.
- [12] T. Joachims, “Text categorization with Support Vector Machines: Learning with many

- relevant features,” dalam *Machine Learning: ECML-98*, vol. 1398, C. Nédellec dan C. Rouveirol, Ed., dalam *Lecture Notes in Computer Science*, vol. 1398. , Berlin, Heidelberg: Springer Berlin Heidelberg, 1998, hlm. 137–142. doi: 10.1007/BFb0026683.
- [13] C.-C. Chang dan C.-J. Lin, “LIBSVM: A library for support vector machines,” *ACM Trans. Intell. Syst. Technol.*, vol. 2, no. 3, hlm. 1–27, Apr 2011, doi: 10.1145/1961189.1961199.
- [14] Ulummuddin, I., Puspita Sari, A., & Hanindia Prami Swari, M. (2024). PEMANFAATAN DATA ULASAN PENGGUNA UNTUK MEMBANGUN SISTEM KLASTERISASI BERDASARKAN PAIN POINTS MENGGUNAKAN ALGORITMA K-MEANS. *Jurnal Teknologi Terpadu*.
- [15] H. Hariyadi, D. Firdo, dan M. H. Al Rafi, “Implementasi Algoritma Naïve Bayes dan Support Vector Machine pada Analisis Sentimen Ulasan Aplikasi Canva,” *J. Minfo Polgan*, vol. 13, no. 1, hlm. 261–269, Mar 2024, doi: 10.33395/jmp.v13i1.13568.
- [16] N. A. Maulana dan D. Darwis, “Perbandingan Metode SVM dan Naïve Bayes untuk Analisis Sentimen pada Twitter tentang Obesitas di Kalangan Gen Z,” *J. Pendidik. Dan Teknol. Indones.*, vol. 5, no. 3, hlm. 655–666, Mar 2025, doi: 10.52436/1.jpti.691.

LAMPIRAN

A. Kontribusi Anggota

No.	Jenis Kegiatan	Kontribusi	Catatan
1.	Menentukan topik project	Aulia Aziza Fauziah R. W. Ulfia N. R.	Mencari dan mengumpulkan ide-ide judul project yang nantinya akan dipilih salah satu yang terbaik.
2.	Menentukan Teknik Pre-processing dan metode Feature Engineering yang digunakan	Aulia Aziza Fauziah R. W. Ulfia N. R.	Mencari dan mengumpulkan metode-metode terbaik yang sesuai dengan judul project
3.	Mencari data dan referensi acuan yang digunakan	Aulia Aziza Fauziah R. W. Ulfia N. R.	Mencari dan mengumpulkan data dan referensi untuk acuan project
4.	Menyusun latar belakang, manfaat dan tujuan pada laporan	Aulia Aziza Fauziah R. W. Ulfia N. R.	Menyusun latar belakang sesuai dengan referensi, manfaat yang diharapkan, dan tujuan yang ingin dicapai.
5.	Implementasi code tahap Pre-processing	Aulia Aziza Fauziah R. W. Ulfia N. R.	Menerapkan code tahap Pre-processing pada data yang telah dikumpulkan
6.	Implementasi code tahap EDA hasil Pre-processing	Aulia Aziza Fauziah R. W. Ulfia N. R.	Menerapkan code tahap EDA hasil Pre-processing pada data yang telah dikumpulkan
7.	Pemodelan Menggunakan Naive Bayes (MultinomialNB)	Aulia Aziza Fauziah R. W. Ulfia N. R.	Melakukan klasifikasi sentimen menggunakan model Naive Bayes
8.	Pemodelan Menggunakan Support Vector Machine (SVM)	Aulia Aziza Fauziah R. W. Ulfia N. R.	Melakukan klasifikasi sentimen menggunakan model Support Vector Machine (SVM)
9.	Menentukan Metrik Evaluasi	Aulia Aziza Fauziah R. W. Ulfia N. R.	Menentukan Metrik Evaluasi yang relevan dengan project.

10.	Clustering menggunakan algoritma K-Means	Aulia Aziza Fauziah R. W. Ulfia N. R.	Melakukan proses clustering topik pada dua kelas sentimen (positif, negatif) menggunakan K-Means.
11.	Menyusun rencana dan langkah selanjutnya	Aulia Aziza Fauziah R. W. Ulfia N. R.	Menyusun rencana dan langkah selanjutnya untuk hasil yang lebih baik.
12.	Menyusun kesimpulan dan saran	Aulia Aziza Fauziah R. W. Ulfia N. R.	Menyusun kesimpulan dari project dan saran untuk kedepannya.

B. Link Data

1. Link data web scraping
 Data Sentiment DANA.xlsx
2. Link data Pre-Processing
 Data Sentiment DANA-PREPO.xlsx
3. Link Data Pelabelan
 Data Sentiment DANA label.xlsx
4. Link Data Pemodelan
 Data Sentiment DANA pemodelan.xlsx

C. Link Youtube

-  Pemaparan Hasil Project kelp. 08

D. Link Google Colab

-  Project UAS Pemteks_.ipynb